Arquitectura de Ordenadores

Práctica 4. Explotar el potencial de las arquitecturas modernas.

ESCUELA POLITÉCNICA SUPERIOR. UAM.

Contenidos

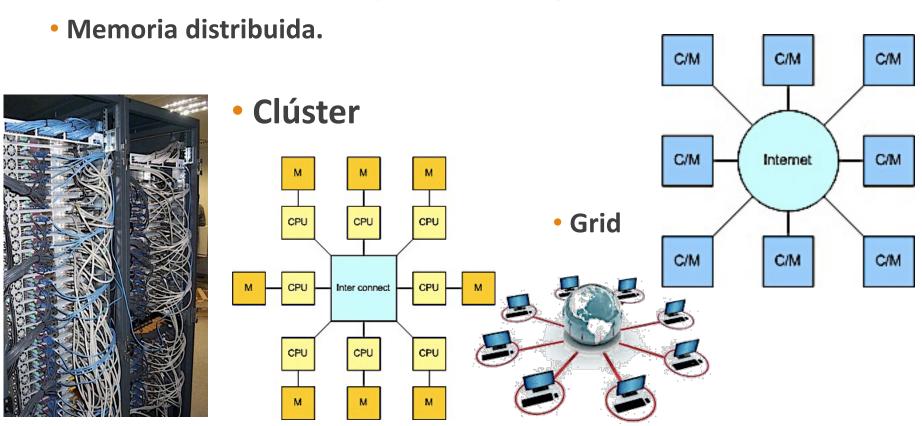
- Arquitectura de computadores (Tema 4)
 - Multicomputador, Multiprocesador, Multicore
 - Hyperthreading
- Programación paralela en sistemas de memoria compartida (multiprocesador multicore)
 - O POSIX threads: pthreads
 - OpenMP
- Práctica 4
 - Entorno
 - Ejercicios

Arquitecturas para Computación paralela: (HPC)

- Hoy en día las máquinas con las que trabajamos disponen de muchas unidades de proceso interconectadas
- Diversos niveles de interconexión
 - Multicomputador
 - Multiprocesador
 - Multicore
- Mediante computación/programación paralela podemos sacar partido de estos sistemas

Multicomputador

- Diversos ordenadores conectados entre sí.
- Comunicación basada en paso de mensajes.



Multiprocesador

 Ordenador con más de una unidad física de proceso (procesador/nodo) conectadas a una memoria compartida

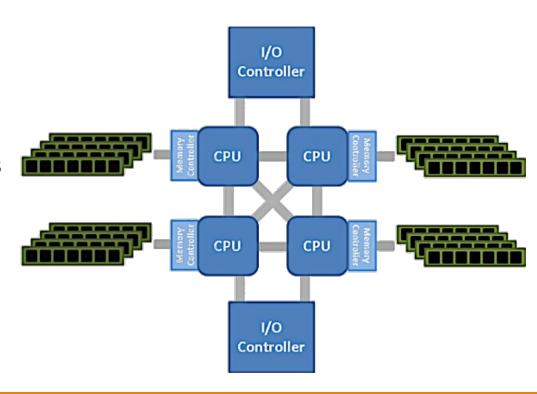
- Dos tipos
 - O UMA

Uniform Memory Access

O NUMA

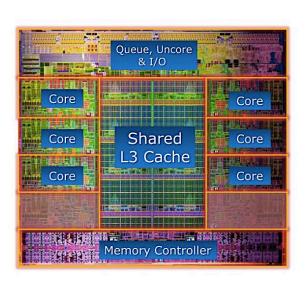
Non-Uniform Memory Acces

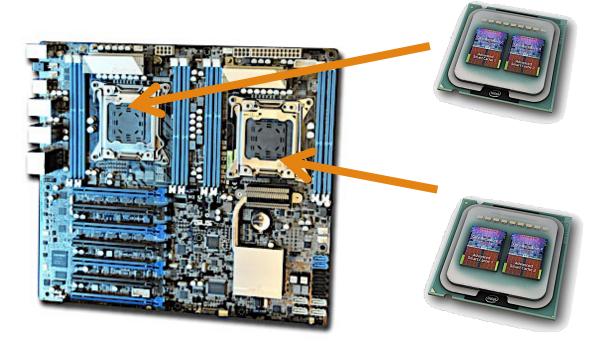
- Paralelismo
 - Procesos
 - Hilos (Threads)



Sistemas de memoria compartida actuales

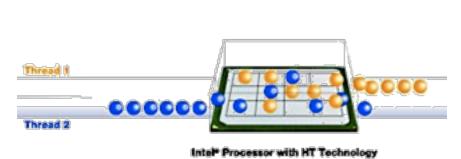
- Multiprocesador-multicore (MP-MC): Un procesador multicore combina en un mismo encapsulado dos o más microprocesadores independientes (demonina core)
- Memoria compartida: Acceso NUMA:





Cores Lógicos versus cores físicos: Hyperthreading

- Cada procesador maneja dos threads
 - Cuando el que está ejecución se bloquea, entra el otro
 - Estructura HW para hacer un cambio de contexto del procesador (registros, ...)
- Número de procesadores x 2
 - ¡No es real!
 - Útil en sistemas de sobremesa
 - Muchos bloqueos
 - No siempre útil en HPC
 - Nº bloqueos mínimo



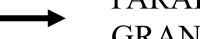
Modelo de programación de sistemas con memoria compartida

Características

· Varios procesos o threads ejecutándose en un espacio de direcciones común

Alternativas

- usar un lenguaje paralelo nuevo, o modificar la sintaxis de uno secuencial (HPF, UPC... / Occam, Fortran M...).
- trabajar directamente con procesos/threads: Pthreads (POSIX)
- usar un lenguaje secuencial junto con directivas al compilador con rutinas de librería. para especificar el paralelismo. OPENMP
 - ¿Cómo explotar el paralelismo?
 - A nivel de programas
 - A nivel de subrutinas
 - A nivel de bucles
 - A nivel de sentencias



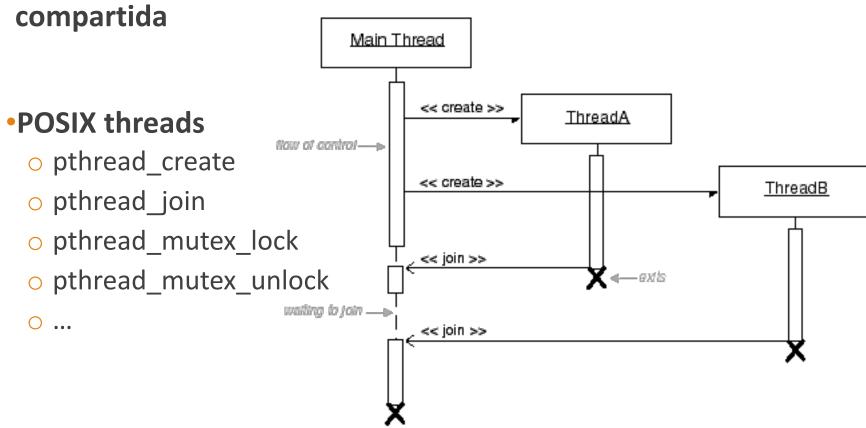




PARALELISMO GRANO FINO

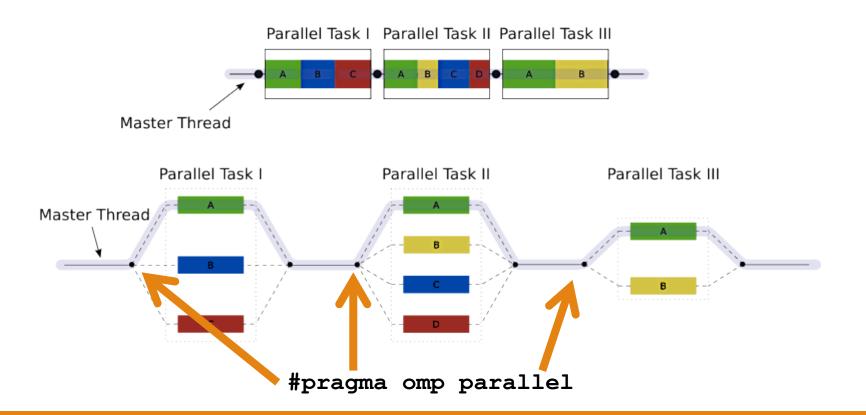
Modelo de programación de sistemas con memoria compartida: PThreads

Programación basada en hilos comunicados por memoria



Modelo de programación de sistemas con memoria compartida: OpenMP

 Ofrece un API basado en pragmas para simplificar el manejo de hilos en sistemas MP-MC



OpenMP

El estándar OpenMP se usa en la programación de computadores paralelo con un espacio de direcciones compartido.

 OpenMP es una API (Application Program Interface) que permite definir explícitamente paralelismo multi-thread en sistemas de memoria compartida. (Compilador OpenMP para C/C++ y Fortran)

OpenMP esta divido en tres componentes principales:

- Directivas de compilación
- Librería de rutinas (Runtime Library)
- Variables de entorno
- Las aplicaciones desarrolladas con OpenMP son portables a todas las arquitecturas de memoria compartida que cuenten con un compilador de OpenMP.
- No realiza una paralelización automática.

OpenMP: Componentes

Directivas

- Regiones Paralelas
- Work sharing
- Sincronización
- Clausulas
 - private
 - firstprivate
 - lastprivate
 - shared
 - reduction

Variables de Entorno

- Nº threads
- Tipo scheduling
- Ajuste dinámico threads
- Paralelismo anidado

Runtime API

- No threads
- ID thread
- Tipo scheduling
- Ajuste dinámico threads
- Paralelismo anidado

OpenMP: Formato de las directivas

```
#pragma omp nombre de directiva [clause, ...]
```

- #pragma omp
 Requerido por todas las directivas OpenMP para C/C++
- nombre_de_directiva
 Un nombre valido de directiva. Debe aparecer después del pragma y antes de cualquier clausula.
- [clause, ...]

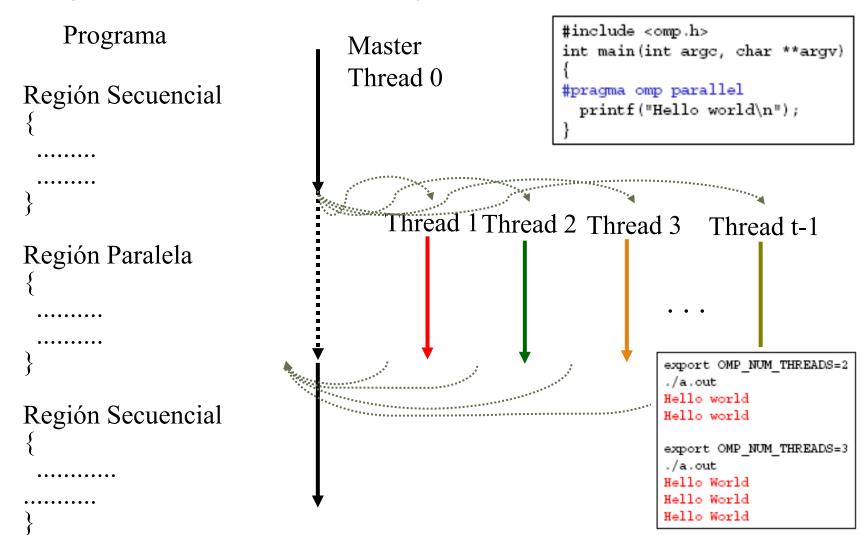
Opcionales. Las clausulas pueden ir en cualquier orden y repetirse cuando sea necesario a menos que haya alguna restricción.

```
#pragma omp parallel default(shared) private(beta, pi)
```

Directiva parallel

- Su aparición en el código significa la delimitación de una región paralela
- Al inicio de la región paralela, se lanzan tantos hilos como se haya indicado
- Al final de la región paralela, se realiza una sincronización de todos los hilos
 - Hasta que todos hayan acabado no se continúa con el programa
- Este lanzamiento/sincronización de hilos implica un coste en términos de tiempo de ejecución que no se puede obviar

Regiones paralelas y secuenciales



OpenMP:Región Paralela

Una región paralela es un bloque de código que será ejecutado por múltiples threads

Es la construcción paralela fundamental de OpenMP

structured_block

OpenMP: programa de ejemplo

```
#include <omp.h>
                 #include <stdio.h>
            2
            3
                 int main(int argc, char *argv[])
              ₩
            5
            6
                      int tid, nthr, nproc;
            7
                      int arg;
                     nproc = omp_get_num_procs();
                     printf("Hay %d cores disponibles\n", nproc);
           10
           11
                     arg = atoi( argv[1] );
           12
                     omp_set_num_threads(arg);
           13
                     nthr = omp get max threads();
           14
                      printf("Me han pedido que lance %d hilos\n", nthr);
           15
           16
                      #pragma omp parallel private(tid)
           17
           18 ▼
                          tid = omp_get_thread_num();
región paralela
                          nthr = omp_get_num_threads();
                          printf("Hola, soy el hilo %d de %d\n", tid, nthr);
           21
           22
           23
```

Conceptos Básicos

- Una región paralela es un bloque de código ejecutado por todos los threads simultáneamente
 - El thread maestro tiene el ID 0
 - El ajuste (dinámico) de threads (si esta activado) se realiza antes de entrar a la región paralela
 - Podemos anidar regiones paralelas, pero depende de la implementación
 - Podemos usar una clausula if para hacer que una región paralela se ejecute de forma secuencial
- Las construcciones "work sharing" permiten definir el reparto del trabajo a realizar en la región paralela, entre los threads disponibles
 - No crea nuevos threads

Otro ejemplo: suma de vectores

Paralelización de la suma de dos vectores:

Para compilar con GCC : gcc –fopenmp ejemplosuma.c –o ejemplosuma –lgomp

Qué resuelve OpenMP

- Creación de los equipos de hilos
- Sincronización al terminar la región paralela
- Librería de funciones para acceder a/modificar datos relacionados con el equipo de trabajo
 - ¿Quién soy?: omp_get_thread_num()
 - ¿Con quién voy?: omp_get_num_threads()
 - Cambiar tamaño del equipo: omp_set_num_threads()
 - O ...
- Generación de copias locales de las variables definidas como privadas
- Asignación de afinidad a cada thread del equipo

OpenMP: Runtime API

- El estandar OpenMP define un API de llamadas para realizar una serie de funciones:
 - Obtener/Establecer el número de threads a usar.
 - Obtener el identificador de thread.
 - Rutinas de bloqueo de propósito general (semaphores)
 - Establecer funciones de entorno de ejecución: paralelismo anidado, ajuste dinámico de threads, etc.
 - void omp_set_num_threads(int num_threads): Fija el número de threads que serán utilizados en la próxima región paralela. Sólo puede invocarse desde una sección secuencial de código
 - int omp_get_num_threads(void): Si se invoca desde una sección secuencial de código, o de una región paralela anidada que se ha serializado, retorna 1
 - int omp_get_thread_num(void): Devuelve el número del identificador del thread en el equipo desde el que se invoca. Este número estará entre 0 y omp_get_num_threads-1

Ejecución con varios Threads

Establecer numero de threads con variable de entorno

- Se hace a través de la variable de entorno OMP_NUM_THREADS
- Variable de entorno en Linux (Bash): export OMP_NUM_THREADS=3 ejemplosuma

Dentro del programa con código (función de librería)

Consideraciones al programar OpenMP

- Definir el número de hilos, identificar cada hilo.
 - Ejercicio 1
- Definir correctamente la accesibilidad de las variables utilizadas
 - o public/private
 - Ejercicio 1 y 4
- Gestionar la recogida de resultados del equipo de hilos
 - Reduction
 - Ejercicio 2 y 4
- Colocación más adecuada del pragma parallel
 - Ejercicio 3

OpenMP: Reparto de tareas

Construcciones de trabajo compartido

Distribuyen la ejecución de las sentencias asociadas entre los threads definidos. No lanzan nuevos threads.

OpenMP define las siguientes construcciones de trabajo compartido:

- Construcción for
 - Define una región donde las iteraciones del bucle deben ejecutarse entre los threads que lo encuentren

```
#pragma omp for [clausulas ...]

lazo for
```

Construcción sections

Directiva for

- Puede usarse dentro de una región paralela ó combinado con parallel antes de un bucle (que pasará a ser la región paralela)
- Reparte de forma automática el trabajo entre los threads del equipo
 - o Declara automáticamente la variable índice como privada



Directiva for

```
#pragma omp for
                                   for(i=0;i<100;i++)
                                                                   for(i=75;i<100;i++)
for(i=0;i<25;i++)
                                             for(i=25;i<50;i++)
                     for(i=50;i<75;i++)
                                                    Thread 2
                              Thread 1
                                                                            Thread 3
      Thread 0
```

#pragma omp parallel

Construcción "Work-Sharing" Directiva for

La directiva *for* especifica que las iteraciones del bucle deben ser ejecutadas en paralelo por el equipo de threads

 Se asume que la región paralela ya ha sido iniciada, de otro modo se ejecutarán en serie

Directiva parallel for

Las directivas parallel y for pueden juntarse en

```
#pragma omp parallel for
```

cuando la región paralela contiene únicamente un bucle.

```
void Suma(double* a, double* b, double* c, int
size)
{
    #pragma omp parallel for
    for (int i = 0; i < size; ++i)
    {
        c[i] = a[i] + b[i];
    }
}</pre>
```

Clausulas y modificadores de las directivas

Las directivas suelen ir acompañadas de cláusulas o modificadores

```
#pragma omp directive_name [parameter list]

• #pragma omp parallel private(iam, nthreads)
```

Ejemplo:

```
#pragma omp parallel for private(i) shared(y,x,alfa,n)
for (i=0; i<n; i++) {
    x[i]= alfa * y[i];
}</pre>
```

Ámbito de variables

El thread máster tiene como contexto el conjunto de variables del programa, y existe a lo largo de toda la ejecución del programa.

Al crearse nuevos *threads*, cada uno incluye su propio contexto, con su propia pila, utilizada para las rutinas invocadas por el *thread*.

Cómo se comparten las variables es el punto clave en un sistema paralelo de memoria compartida, por lo que es necesario controlar correctamente el ámbito de cada variable.

Las variables globales son compartidas por todos los *threads*. Sin embargo, algunas variables deberán ser propias de cada *thread*, privadas.

Cláusulas de ámbito

El ámbito de validez de cada variable, se indica con una serie de cláusulas a la directiva parallel

Cláusulas

```
- shared, private, firstprivate(var)
  default(shared/none)

reduction(op:var)
  copyin(var)
- if (expresión)
- num_threads(expresión)
```

Las variables privadas no están inicializadas al comienzo ,ni dejan rastro al final.

- Si se necesita hay que que declararlas firstprivate para poder pasar un valor a estas variables
- Es privada al thread pero se inicializa con el valor de la variable del mismo nombre en el thread master.

Region Paralela: Cláusulas de ámbito

Ejemplo:

```
X no está

X = 2;
Y = 1;

#pragma omp paraliel
shared(Y) private(X,Z)
{ Z = X * X + 3;
    X = Y * 3 + Z;
}

printf("X = %d \n", X);

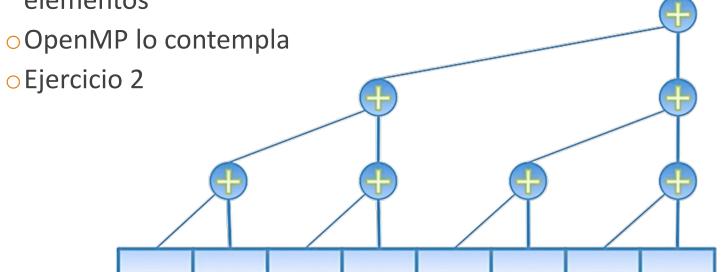
X no está
inicializada!

X no mantiene
x no mantiene
x el nuevo valor
```

Reducción

- Problema típico en programación paralela
- Cada hilo genera un resultado parcial, que se debe recoger y computar para obtener un resultado final

<u>Ej:</u> suma de N elementos con T hilos, cada hilo ha sumado N/T elementos



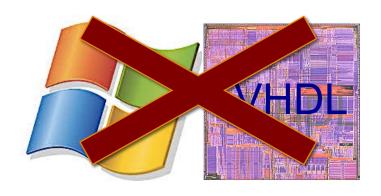
Compilar programas OpenMP

- Muchos compiladores soportan el uso de OpenMP
- Vamos a utilizar el soporte de gcc para openmp
 - Flags al compilar:
 - o -lgomp : librería con la funciones
 - o -fopenmp : soporte de los pragmas

• Está incluido en el fichero Makefile de partida

Práctica 4: entorno de de trabajo

•A lo largo de las prácticas 3 y 4 vamos a trabajar utilizando *software* para poner en práctica los conceptos *hardware* de teoría







Práctica 4: material de partida

- <u>arqo4.c/arqo4.h</u>: librería de manejo de matrices/vectores de números en coma flotante
- •<u>omp1.c/omp2.c</u>: ejemplos de programación utilizando OpenMP
- pescalar_serie.c: versión serie de un programa que realiza el producto escalar de dos vectores
- •pescalar_par1.c: intento de paralelizar un producto escalar
- Makefile: fichero utilizado para la compilación de los ejemplos aportados.
- •pi_serie.c y pi_par1.c a pi_par7.c: versiones serie y paralelo de cálculo de pi por integración numérica.
- edgeDetector.c: programa que detecta bordes en una imagen.

- Identificar de qué tipo es el equipo donde ejecutamos el programa con openMP.
 - ¿Multiprocesador?
 - #procesadores
 - o ¿Multicore?
 - #cores
 - ¿Hyperthreading?

cat /proc/cpuinfo

- Ejercicio1: Ejecutar y comprender ejemplos básicos de OpenMP
 - Lanzamiento de un equipo de hilos
 - Utilización de las funciones básicas de OpenMP
 - Declaración de variables privadas/públicas
 - Contestar a las preguntas de la memoria

Producto escalar de dos vectores

- Paralelo vs Serie
- o ¿Funcionan correctamente al paralelizar?. Resolverlo.
- Análisis del rendimiento al variar parámetros
 - Tamaño del vector
 - Número de hilos
- Contestar a las preguntas de la memoria

- Ejercicio 3: Multiplicación de matrices
 - ¿Qué bucle es mejor paralelizar?
 - Análisis de rendimiento
 - Contestar preguntas de la memoria

- Ejercicios 4: Tutorial www.openmp.org
 - False Sharing
 - ¿ Que es el falso compartir?
 - Análisis de rendimiento
 - Contestar preguntas de la memoria

- Ejercicio 5: Optimizar un programa de procesamiento de imágenes con distintas opciones.
 - Lectura/escritura de las imágenes eficiente.
 - Mejor aprovechamiento de caches.
 - ¿Qué bucle es mejor paralelizar?
 - Optimizaciones adicionales por el compilador
 - Análisis de rendimiento, para diferentes tamaños/calidad de imagen.

Práctica 4: entrega

Entrega:

Ver en Moodle

EXAMEN P4:

Durante el horario de prácticas (ver calendario de prácticas)